

Anatomie d'un système de diagnostic de pannes

De l'équation thermodynamique au tableau de bord — physique, apprentissage et architecture

SEPTEMBRE 2026

0. Le problème et la contrainte fondatrice

Une pompe à chaleur tombe rarement en panne d'un coup. Elle se dégrade. Le condenseur s'encrasse, une fuite lente vide une partie du fluide, un ventilateur faiblit. La machine continue de chauffer, et consomme de plus en plus pour le même service. Le **COP** — la chaleur fournie divisée par l'électricité consommée — glisse de 4,0 à 3,2 en quelques mois. Personne ne le voit ; la facture monte de 25 %.

Le technicien n'a pas besoin d'apprendre qu'il y a un problème. Il a besoin de savoir **lequel**. Et c'est difficile parce que des pannes très différentes se ressemblent : un condenseur encrassé et un ventilateur de condenseur défaillant font tous deux monter la pression haute et chuter le COP. L'un se règle avec un nettoyage, l'autre avec une pièce.

La contrainte qui commande tout le reste

Pour apprendre à nommer une panne, il faut des exemples étiquetés. Or ces données sont **rare et chères** : il faut délibérément encrasser un condenseur, retirer de la charge, brider un ventilateur, et instrumenter la machine pendant qu'on l'abîme. Peu de laboratoires le font.

Ce projet répond par la simulation. Ce n'est pas un contournement, c'est **la réponse standard du domaine** — le NIST et l'ASHRAE procèdent de même, et la rareté des données de défaut est précisément ce qui motive leurs campagnes d'essais.

Mais ce choix crée une tension qu'il faut annoncer d'emblée : **si le même modèle fabrique les questions et les réponses, que mesure-t-on exactement ?** La seconde moitié de ce document ne traite que de cela.

Comment lire ce document

Le système est parcouru module par module, dans l'ordre où circule une mesure. À chaque étape, trois questions :

Physique	Quel phénomène est modélisé, avec quelle équation
Apprentissage	Quelle décision de modélisation cela impose
Ingénierie	Pourquoi ce code vit ici et pas ailleurs

Structure du dépôt

```
heat-pump-fdd/
|
+-- src/
|   +-- physics/           le modèle physique – n'importe rien du projet
|   |   +-- simulator.py   cycle R-410A, injection des défauts
|   |   +-- thermo_lab.py  balayages COP, enveloppes
|   |   +-- thermodynamic_viz.py diagrammes pression-enthalpie
|   |
|   +-- fdd/               la méthode – partagée par toutes les études
|   |   +-- features.py    contrat des 24 grandeurs, résidus
|   |   +-- ml_models.py   entraînement, sélection de modèle
|   |   +-- inference.py   FDDEngine : charger, diagnostiquer
|   |   +-- visualization.py figures d'entraînement
|   |
|   +-- studies/           les jeux de données
|       +-- synthetic/
|           +-- generator.py tirage, injection, assemblage
|           +-- taxonomy.py  les classes de panne de cette étude
|           +-- scenarios.py  la démo : simulate_cycle, live_trace
|           +-- paths.py     source unique des chemins d'artefacts
|
+-- api/                   FastAPI – 4 routes d'inférence, 17 de tableau de bord
+-- web/                   React – lit la liste des grandeurs depuis l'API
+-- tests/                 43 tests, dont 5 gardes d'architecture
+-- EDA/                   notebooks de confrontation aux essais mesurés
+-- docs/                  documentation technique et ce dossier
|
+-- outputs/synthetic/     jeu de données et figures, par étude
+-- models/synthetic/      modèle sérialisé et ses métadonnées
```

La règle d'import est à sens unique et vérifiée par des tests :

studies/ → fdd/ → physics/

1. La physique — `src/physics/`

`simulator.py` — la source de vérité

Ce module calcule un cycle à compression de vapeur au R-410A. Il est la racine de la dépendance : tout s'appuie sur lui, il ne s'appuie sur rien. Les propriétés du fluide viennent de CoolProp, avec des corrélations de repli.

Trois entrées définissent un point de fonctionnement :

Entrée	Plage	Sens
T_{source}	−10 à 20 °C	Air extérieur, côté froid
T_{sink}	30 à 55 °C	Eau de chauffage, côté chaud
n	0,3 à 1,0	Régime du compresseur

Le point nominal est **A7/W40** : air à 7 °C, eau à 40 °C.

Le modèle d'échangeur, et l'exposant qui fait tout

$$UA_{evap} = UA_{evap}^{nom} (1 - 0,50 \varphi_{evap}) r_{evap}^{1,45}$$

$$UA_{cond} = UA_{cond}^{nom} (1 - 0,50 \varphi_{cond}) r_{cond}^{1,45}$$

avec $UA_{evap}^{nom} = 500$ W/K et $UA_{cond}^{nom} = 600$ W/K ; φ l'encrassement (0 = propre) et r le débit d'air rapporté au nominal.

Physique. UA est le coefficient global d'échange : combien de chaleur passe par degré d'écart. L'encrassement dépose une couche isolante et le dégrade **linéairement**. Une perte de débit d'air le dégrade avec un **exposant 1,45**, parce que la convection côté air s'effondre plus vite que proportionnellement au débit.

Apprentissage. C'est le cœur du projet. Les deux pannes dégradent la même grandeur, mais par deux lois différentes. C'est *cette* différence qui rend les classes séparables. Sans elle, il n'y a pas de problème de classification — seulement deux noms pour un même symptôme.

L'écart de température aux bornes de l'échangeur, le *pincement*, en découle :

$$\Delta_{evap} = 5 + 7 \left(1 - \frac{UA_{evap}}{UA_{evap}^{nom}} \right)$$

$$\Delta_{cond} = 5 + 7 \left(1 - \frac{UA_{cond}}{UA_{cond}^{nom}} \right) + 8 (1 - r_{cond})$$

puis les températures de changement d'état :

$$T_{evap} = T_{source} - \Delta_{evap} \quad T_{cond} = T_{sink} + \Delta_{cond}$$

À retenir : le condenseur est du côté du puits chaud. Cette convention deviendra un piège au moment de confronter le modèle à des essais mesurés en mode refroidissement, où c'est l'unité extérieure qui joue ce rôle.

Le compresseur

Le rendement isentropique suit une corrélation de compresseur scroll, maximale autour d'un taux de compression $\tau = 3$:

$$\eta_{is} = 0,75 \cdot f(\tau) \cdot g(n), \quad f(\tau) = \text{borne}(1 - 0,05 (\tau - 3)^2, 0,4, 1), \quad g(n) = 1 - 0,30 (n - 0,7)^2$$

$$\eta_{vol} = 1 - 0,05 \left(\tau^{1/k} - 1 \right), \quad \tau = \frac{P_{cond}}{P_{evap}}$$

Lecture utile : un défaut qui écarte τ de son optimum dégrade le COP **deux fois** — par la thermodynamique, et par la chute du rendement du compresseur.

La température de refoulement suit une loi polytropique corrigée par ce rendement :

$$T_{ref}^{ideal} = (T_{asp} + 273,15) \tau^{\frac{k-1}{k}} - 273,15 \quad T_{ref} = T_{asp} + \frac{T_{ref}^{ideal} - T_{asp}}{\eta_{is}}$$

Un compresseur moins efficace transforme davantage de travail en chaleur : il refoule plus chaud. C'est pourquoi la température de refoulement est un indicateur de santé si sensible.

Puissances et COP

$$Q_{cond} = \dot{m} (h_2 - h_3) \quad W_{comp} = 1,10 \cdot \dot{m} \Delta h_{reel} \quad COP = \frac{Q_{cond}}{W_{comp}}$$


Le facteur 1,10 couvre les pertes mécaniques et électriques. Le détail des enthalpies est en annexe B.

Le défaut n'est pas du bruit

Un défaut est un **paramètre physique dégradé en amont** — φ_{cond} , r_{cond} , la charge c — et toutes les grandeurs en découlent de façon cohérente. Une ligne change dans l'appel, le cycle entier est recalculé.

Ingénierie. C'est ce qui permet d'explorer un défaut de façon continue, à n'importe quelle sévérité et dans n'importe quelles conditions — ce qu'aucun jeu d'essais réels ne permet.

Ce que la confrontation aux mesures a révélé



Quatre défauts de modélisation, trouvés en comparant les signatures simulées à des essais mesurés, puis corrigés :

Défaut trouvé	Conséquence
Surcharge sans branche de calcul	Une classe déclarée qui ne produisait aucun effet
Sous-refroidissement inversé sur l'encrassement condenseur	Une grandeur du vecteur variait à l'envers
Surchauffe et refoulement inversés sur le ventilateur d'évaporateur	Deux grandeurs à l'envers
Plafond de refoulement déclaré mais jamais appliqué	Des cycles à 319 °C dans les données d'apprentissage

Le dernier est le plus instructif : $T_{ref}^{max} = 130$ °C figurait dans le code, mais n'était utilisé que pour afficher une alerte — jamais pour borner la valeur. Une partie des exemples décrivait des machines qui ne peuvent pas exister.

`thermodynamic_viz.py` et `thermo_lab.py` — des vues, pas de la physique

Diagrammes pression-enthalpie et balayages de COP. Ils vivent dans `physics/` parce qu'ils manipulent les mêmes propriétés du fluide, mais sont importés par l'API et **jamais par le pipeline d'apprentissage**. Une visualisation n'entre pas dans un vecteur de features.

2. Du cycle au vecteur — `src/fdd/features.py`

Le problème de représentation

Un résultat de cycle n'est pas un vecteur exploitable. Il faut décider **quoi** montrer au modèle — et ce choix pèse plus lourd que celui de l'algorithme.

Le contrat compte 24 colonnes : 3 conditions, 16 grandeurs mesurées ou dérivées, 5 **résidus**.

Les résidus, ou l'analogie de la fièvre

Dire « 37,8 °C » ne veut rien dire tant qu'on ignore de qui l'on parle. Dire « 0,9 °C au-dessus de sa température habituelle » est un signal, quel que soit l'individu.

$$\tilde{x} = x_{observe} - \hat{x}_{sain}(T_{source}, T_{sink}, n)$$

Une surchauffe de 12 K ne dit rien : elle dépend de la machine, de la saison, de la charge. Une surchauffe **1,7 K au-dessus de ce que cette machine-ci ferait en bonne santé, maintenant** est une signature de sous-charge.

Apprentissage. C'est la méthode des résidus de Li et Braun : un modèle de référence prédit le comportement sain, le classifieur travaille sur l'écart. Le docstring du module la nomme.

La couture qui rend toute la validation possible

```
def cycle_to_features(result, ..., baseline=None, ...):
    if baseline is None:
        baseline = healthy_cycle(T_source, T_sink, speed_ratio)    # <- simule
```

Par défaut, le cycle sain de référence est calculé par le simulateur. Les deux termes de la soustraction sortent de la même machine à calculer : c'est là qu'est la circularité annoncée en ouverture.

Mais le paramètre `baseline` est exposé. Passer un cycle sain **mesuré** transforme les cinq résidus en écarts réels, sans modifier une ligne du reste du pipeline.

Ingénierie. Une seule ligne de signature est ce qui a rendu possible toute la confrontation décrite en partie 7. C'est l'exemple le plus net, dans ce projet, de ce qu'un bon point d'extension fait gagner.

Une redondance

`compression\_ratio` et `pressure\_ratio` sont le même nombre, vérifié à la précision machine sur tous les points testés. Le modèle dispose de 23 entrées indépendantes, pas 24.


3. Fabriquer un jeu de données — `src/studies/synthetic/`

Pourquoi une couche « études » séparée

Un jeu de données n'est pas un fichier. C'est un triplet : **des données, une taxonomie de pannes, un emplacement d'artefacts**. Le jour où une seconde source arrive, rien de la méthode ne doit bouger. C'est la justification du découpage architectural, et elle est vérifiable.

Module	Rôle
<code>generator.py</code>	Tirage des conditions, injection des défauts, assemblage
<code>taxonomy.py</code>	Les classes de panne et leurs paramètres — propre à l'étude
<code>scenarios.py</code>	La démo : <code>simulate_cycle</code> , <code>live_trace</code> — pas la méthode
<code>paths.py</code>	Source unique des chemins, aucun chemin en dur ailleurs

Les conditions sont tirées uniformément dans le domaine, un défaut est choisi puis injecté à une sévérité tirée, et le cycle est recalculé.



Sept classes sont produites : sain, encrassement de condenseur, encrassement d'évaporateur, sous-charge, **surcharge**, ventilateur de condenseur, ventilateur d'évaporateur. La surcharge est générée depuis P4, après retrait d'un `condenser_fouling` parasite qui contaminait chaque échantillon. La fuite de clapet a été **retirée** : le simulateur n'a pas de paramètre de rendement volumétrique, et l'ancienne branche était un mélange de sous-charge et d'encrassement évaporateur.

Le bruit de mesure

Un bruit gaussien est ajouté aux grandeurs qu'un capteur mesure : 0,5 °C sur les températures, 2 % sur les pressions, 3 % sur les puissances. Il ne modélise ni dérive de capteur, ni biais, ni régime transitoire.

Les grandeurs dérivées sont recalculées après ce bruit, et la référence saine des résidus `d_*` est bruitée indépendamment. Sur les 5000 exemples, chaque ligne vérifie **`pressure\_ratio`** = P_{cond}/P_{evap} et **`COP`** = Q_{cond}/W_{comp} .

Avant cette correction, `d_COP` n'était bruité d'aucun côté : il valait exactement 0 pour les 2000 essais sains, et pour eux seuls. Un arbre à une feuille séparait défaut de sain à 100 %. C'était l'étiquette de détection en clair dans le vecteur d'entrée. Le 99,6 % publié alors était invalide. Le chiffre honnête, après fermeture des quatre fuites du pipeline, était **91,9 % [90,4 – 93,1]** sur six classes. P4 a ajouté la surcharge : le chiffre livré est **89,3 % [87,6 – 90,7]** (hold-out, sélection sur val, sept classes).

La portée de ce qui reste dans le modèle — partie suivante.

4. Le modèle — `src/fdd/ml_models.py` et `inference.py`

Le choix d'algorithme, et pourquoi il compte peu


Forêt aléatoire, sélectionnée sur le jeu de validation. Gradient Boosting calibré en probabilité, à égalité sur val ($\Delta F1 = 0,002$) — départagé sur l'inférence et l'interprétabilité. Scaler et classifieur dans un

`sklearn.Pipeline` . Split 2625 / 875 / 1500 (train / val / test). Le test ne sert jamais à choisir.

Modèle	Accuracy test	IC 95 %	F1 test	F1 val
Forêt aléatoire (livré)	89,3 %	87,6 – 90,7	0,872	0,896
Gradient Boosting calibré	90,5 %	88,9 – 91,9	0,882	0,899


Validation croisée 5 plis **sur le train seulement** : F1 $0,881 \pm 0,017$.

Pourquoi pas douze algorithmes. Les deux candidats sont à égalité sur val ($\Delta F1 = 0,003$). Empiler des algorithmes aurait donné une **illusion de rigueur**. Le travail utile était dans le protocole : ne pas choisir sur le test, publier un intervalle.



La matrice de confusion n'est plus quasi parfaite. Les ventilateurs restent séparés (F1 0,97) ; la surcharge est détectée (F1 0,88) et ne se confond pas avec l'encrassement condenseur (11 / 150 et 9 / 150 dans les deux sens) une fois le couplage artificiel retiré. Les deux encrassements restent les classes difficiles (0,71 et 0,79). C'est de la physique : les deux élèvent la pression haute.

Ce dont le modèle se sert réellement



Cette figure est la plus instructive du jeu simulé, pour deux raisons.

D'abord, 18 des 24 grandeurs ont une importance quasi nulle. Le modèle en utilise six. Le contrat de features est donc largement surdimensionné, ce qui prépare une simplification (P5).

Ensuite, **d_COP** n'est plus le pilier de la décision.

Rang	Grandeur	Importance
1	delta_T_cond	0,140
2	delta_T_evap	0,131
3	superheat	0,129
4	d_T_discharge	0,118
5	subcooling	0,088
6	d_W_comp	0,078
9	d_COP	0,036

Avant correction, `d_COP` + `delta_T_cond` + `delta_T_evap` portaient 76 % de l'importance, et les trois étaient exempts de bruit. Après recalcul des dérivées, `d_COP` tombe à 3,6 %. Les pinches restent utiles — ils sont désormais cohérents avec les températures bruitées.

FDDEngine — charger et diagnostiquer, rien d'autre

Le moteur charge un modèle et attribue une classe à un vecteur. Il ne sait pas simuler un défaut : cela appartient à l'étude.

Cette séparation n'a pas toujours existé. Le moteur contenait initialement le générateur de défauts, ce qui faisait dépendre la couche partagée d'une étude particulière et interdisait d'en ajouter une seconde. Le découplage a été fait **avant** tout déplacement de fichier, et cinq tests l'empêchent de revenir.

Le modèle versionné et le pin porteur

Le modèle entraîné est **sérialisé et versionné dans le dépôt**, pour que le projet se clone et tourne sans réentraînement. Ce format dépend de la version exacte de la bibliothèque, épinglée à `scikit-learn==1.6.1`. Une autre version rend le modèle illisible, avec une erreur qui ne ressemble pas à un problème de version :


```
ModuleNotFoundError: No module named '_loss'
```

L'image Docker est protégée puisqu'elle installe depuis le fichier de dépendances ; un environnement local qui a dérivé ne l'est pas.

5. Servir — `api/` et `web/`

Famille	Nombre	Rôle
Inférence	4	<code>/health</code> , <code>/predict</code> , <code>/simulate</code> , <code>/live</code>
Tableau de bord	17	<code>/api/*</code> — alimenter les vues

Vingt-et-une routes dans un module de 582 lignes, pour deux responsabilités : la couture d'un découpage à venir est nette.



Le contrat d'entrée est strict. `/predict` énumère les 24 grandeurs et refuse tout champ inconnu — une grandeur mal nommée est rejetée plutôt qu'ignorée. Cela fait de toute évolution du contrat une **rupture de compatibilité**.

Le front est générique : il lit la liste des grandeurs depuis l'API. Il suivra une évolution sans modification.

6. La règle qui tient l'ensemble

studies/ → fdd/ → physics/

`physics/` n'importe rien du projet ; `fdd/` peut importer `physics/` ; seule `studies/` peut importer les deux.

Ce que la règle interdit : que la méthode dépende d'un jeu de données particulier.

Ce qui la maintient : cinq tests qui échouent si le couplage revient — le moteur ne doit pas exposer d'interface de simulation, le module de features ne doit pas contenir de taxonomie d'étude, l'entraîneur ne doit pas importer de générateur.

Le récit du refactor

L'ordre a compté plus que le contenu :

1. **Découpler d'abord**, sans déplacer un fichier.
2. **Déplacer ensuite**, sans changer une ligne de logique.
3. **Ranger les artefacts par étude** en dernier.

Inverser les deux premières étapes aurait noyé une décision d'architecture dans une dizaine de renommages.

L'équivalence de comportement a été vérifiée à chaque étape en comparant les sorties avant et après — six types de défaut, leurs 24 grandeurs, la classe prédite, la confiance, une trace temporelle. Identiques octet pour octet.


Pour le jury. Un refactor ne se juge pas sur l'élégance du résultat mais sur la preuve que rien n'a bougé. Ici la preuve est une comparaison binaire des sorties, pas une suite de tests verte : les tests disent que le contrat tient, pas que les nombres sont les mêmes.

7. Les données mesurées

La validation s'appuie sur une campagne publique du NIST : des pompes à chaleur résidentielles en chambre climatique, avec défauts imposés et maintenus.

Essais	7375
Grandeurs	98 colonnes, côté air et côté fluide
Machines	Deux, de performances différentes
Retenus	5386 essais à défaut unique, 6 classes
Mode	Refroidissement

Deux machines plutôt qu'une : c'est décisif, car cela permet de tester si un modèle appris sur l'une fonctionne sur l'autre.




Les classes ne sont pas données : elles sont **implicites**, réparties sur cinq colonnes de niveau où 100 % signifie nominal. Un défaut compte comme actif dès que son niveau s'écarte de plus de 2 % — seuil qui reproduit exactement les effectifs publiés, ce qui permet de l'inscrire en assertion dans le code.

Trois obstacles méthodologiques


Le mode est inversé. Les essais sont en refroidissement, le simulateur en chauffage. En refroidissement, c'est l'unité **extérieure** qui condense — l'inverse de la convention du simulateur. Apparier les pannes sans vérifier ce point conduit à comparer des sens opposés et à conclure que le modèle est faux alors que c'est l'appariement qui l'est.

Un capteur n'est pas instrumenté sur une des deux machines.



La colonne nommée « pression au port d'aspiration » contient en réalité la pression de refoulement sur l'une des deux machines, soit 55 % des essais. Le rapport de pression y vaut exactement 1,00 — physiquement impossible — sans qu'aucune erreur ne soit levée. Le panneau de gauche montre le pic à 1,00 ; celui de droite, la colonne de remplacement, cohérente sur les deux machines.

Les domaines se recouvrent à 5,3 %.



Le rectangle est le domaine sur lequel le simulateur a été entraîné ; les points sont les essais mesurés. Ils tombent presque entièrement à l'extérieur. **Comparer des valeurs absolues est donc exclu** ; seules les tendances sont comparables.

Enfin, les colonnes de niveau de défaut sont la réponse à trouver : les inclure parmi les entrées reviendrait à distribuer le corrigé avec l'énoncé. Elles sont exclues, et un test le vérifie.


8. Les protocoles de validation

Un score n'a aucun sens sans son protocole.

Validation croisée aléatoire : on mélange tous les essais, on en cache une partie. Standard, et trompeur ici, car les essais des deux machines se retrouvent des deux côtés — le modèle peut apprendre à reconnaître *l'installation* plutôt que *la panne*.

Validation par machine (*leave-one-machine-out*) : on entraîne sur une machine, on teste sur l'autre, puis on inverse.

L'analogie est celle d'un élève. Réviser les annales puis composer sur un sujet tiré des mêmes annales donne une bonne note. Composer sur le sujet d'un autre établissement mesure ce qu'il a compris.



Jeu de grandeurs	CV aléatoire	Par machine
Grandeurs brutes	0,954	0,333
Brutes et résidus	0,973	0,562
Résidus seuls	0,937	0,602
Résidus et conditions	0,945	0,594

Classe majoritaire : 0,251.

Deux lectures. **Le jeu qui gagne en validation aléatoire n'est pas celui qui transfère le mieux** : classer des conceptions sur un tirage aléatoire aurait fait retenir la mauvaise. Et **ajouter les grandeurs absolues aux résidus dégrade le transfert**, parce que les valeurs absolues permettent de ré-identifier la machine.

Pour le jury. Un écart de 0,95 à 0,60 entre deux protocoles, même modèle et mêmes données, ne mesure pas le modèle. Il mesure le protocole.

9. Les résultats, et le module que chacun met en cause

L'accord des sens de variation met en cause `simulator.py`

Le recouvrement de 5,3 % interdisant les valeurs absolues, on compare des **directions**. Pour chaque panne et chaque grandeur, on ajuste sur les essais mesurés :

$$x = \beta_0 + \beta_1 L + \beta_2 T_{source} + \beta_3 T_{sink}$$

où L est le niveau de défaut. Les deux derniers termes neutralisent les conditions d'essai, de sorte que β_1 isole l'effet de la panne. On compare **signe**(β_1) au signe de la pente obtenue en balayant le même paramètre dans le simulateur.

	Accord
Avant correction	12 sur 16
Après correction des quatre défauts	20 sur 22

Le dénominateur augmente parce que la surcharge, jusque-là inerte, produit désormais des signaux exploitables.

Ce résultat a directement piloté une réécriture du code. C'est l'intérêt d'une confrontation externe : elle ne note pas le modèle, elle indique quelle ligne corriger.

Le gain des résidus valide `features.py`


Passer des grandeurs brutes aux résidus fait monter la détection de 0,333 à 0,602, pour 1,7 point perdu en validation aléatoire. Le choix de conception du module de features est validé **sur des mesures réelles**, et non par argument théorique.

La dégradation des brutes met en cause `FEATURE_COLUMNS`

Mélanger absolues et résidus fait retomber le transfert de 0,602 à 0,562. Or le contrat actuel contient précisément ce mélange. La mesure désigne une évolution à faire — que l'importance des variables de la partie 4 confirme par un autre chemin.

Le résultat qui réoriente le projet

Une vérification ultérieure a montré que le 0,602 reposait sur une hypothèse implicite : la référence saine — la « température habituelle » de l'analogie — était calculée à partir d'essais sains **de la machine testée**.



Reconstruite à partir de la seule machine d'entraînement, c'est-à-dire face à une machine réellement inconnue, la performance s'effondre. Et **aucune forme de modèle de référence ne lève ce plafond** : ni le polynôme d'ordre 2 avec point de rosée que le NIST décrit lui-même, ni une régression régularisée, ni une forêt aléatoire.

Origine de la référence saine	Accuracy	F1 macro
Essais sains de la machine cible	0,602	0,479
Référence transférée, plus proche voisin	0,318	0,290
Polynôme d'ordre 2 avec point de rosée	0,302	0,254
Forêt aléatoire avec point de rosée	0,265	0,248

Ce n'est pas un échec : c'est une mesure.


Pour le jury. L'écart entre 0,602 et 0,318 est le résultat principal de ce travail. Il ne dit pas que la méthode échoue, il dit ce qu'elle exige : une calibration saine sur la machine en service. Une méthode dont on connaît le prix est utilisable ; une méthode dont on ignore la condition ne l'est pas. Le 0,602 porte lui-même une condition supplémentaire, mesurée depuis et détaillée en [section 13](#) : il suppose une mesure saine à la condition même du défaut. Sur une machine en service, la valeur réaliste est entre 0,43 et 0,52.

10. Le budget de calibration

Si le diagnostic exige d'avoir observé la machine en bonne santé, la question industrielle devient : **combien de temps ?**

Protocole : validation par machine dans les deux sens ; la référence saine est construite sur n essais sains tirés de la machine testée ; ces n essais sont **retirés du jeu de test**, faute de quoi ils serviraient à la fois de calibration et d'évaluation ; vingt tirages par valeur de n , moyenne et intervalle.

Les deux bornes servent de contrôle : $n = 0$ doit retomber sur 0,318 et $n = \text{tous}$ sur 0,602. Les deux ont été retrouvées exactement.



n essais sains	Accuracy	F1 macro
0 — référence transférée	0,318	0,290
10	0,377	0,324
50	0,456	0,380
tous	0,602	0,479

Cinquante essais sains ne récupèrent qu'environ 49 % de l'écart. Atteindre 90 % demande pratiquement l'ensemble. À faible n , l'intervalle est très large : un tirage malheureux fait pire que pas de calibration du tout. Répartir les essais sur le domaine de fonctionnement plutôt que les tirer au hasard aide surtout dans cette zone — les losanges de la figure.

La lecture terrain est directe : **une poignée de mesures de mise en service ne constitue pas une calibration.** C'est la couverture du domaine qui compte — une contrainte de déploiement, non une limite de l'algorithme.

11. Quelles pannes sont réellement détectées

Une moyenne de 0,602 pour un F1 macro de 0,479 : douze points d'écart, donc des classes très inégalement diagnostiquées. Le détail change entièrement ce que le système permet d'affirmer.


Par classe, référence calibrée

Panne	Précision	Rappel	F1	n
Sous-charge	0,748	0,961	0,832	1228
Sans défaut	0,722	0,837	0,741	1352
Surcharge	0,735	0,775	0,674	942
Obstruction condenseur	0,611	0,220	0,299	497
Débit intérieur	0,269	0,313	0,288	774
Ligne liquide	0,206	0,068	0,040	593

Les défauts de charge portent tout le résultat. La sous-charge est cohérente dans les deux sens de transfert — 0,91 et 0,76 — donc ce n'est pas l'artefact d'une machine particulière.

La restriction de ligne liquide n'est jamais détectée : huit vrais positifs sur 492 essais dans un sens. C'est aussi, et ce n'est pas un hasard, la seule panne du jeu mesuré que le simulateur ne modélise pas.

Avec quoi les échecs se confondent




Les deux machines n'ont pas le même mélange de pannes — 856 sous-charges contre 114 surcharges sur l'une, 372 contre 828 sur l'autre — de sorte que les matrices ne peuvent pas être additionnées.

La confusion dominante est physique, pas algorithmique : **le défaut de débit d'air et la restriction de ligne liquide s'échangent massivement**. Les deux affament l'évaporateur, donc abaissent la pression

d'aspiration et la capacité. Sur les grandeurs mesurées, ils se ressemblent — aucun algorithme ne séparera ce que les capteurs ne distinguent pas.

La calibration n'est pas un gain uniforme



Panne	Sans calibration	Avec calibration	Écart
Sans défaut	0,131	0,741	+0,610
Sous-charge	0,481	0,832	+0,351
Obstruction condenseur	0,067	0,299	+0,232
Ligne liquide	0,007	0,040	+0,034
Débit intérieur	0,269	0,288	+0,018
Surcharge	0,786	0,674	−0,111

Deux enseignements.

La calibration sert d'abord à reconnaître l'état sain : +0,61 sur cette seule classe. C'est cohérent — sans référence correcte, le modèle juge tout anormal. Sur une machine, il ne prononce « sans défaut » que dans 2 % des cas.

Et la surcharge est mieux détectée sans calibration qu'avec : 0,786 sur une machine totalement inconnue, cohérent dans les deux sens de transfert. Sa signature — le sous-refroidissement qui s'envole — est assez marquée pour se passer de référence locale.

Le budget de calibration n'est donc pas un chiffre unique. **Il dépend de la panne cherchée, et pour l'une d'elles il est nul.**

Pour le jury. C'est ici que le projet devient utilisable. Non parce que les chiffres sont bons, mais parce qu'ils sont assez détaillés pour dire à un praticien ce sur quoi il peut compter : les défauts de charge, sur une machine jamais vue, dont l'un sans installation préalable.

12. L'apprentissage est-il seulement nécessaire ?

Le diagnostic par résidus est un domaine où la méthode de référence est une **table de règles sur les signes** : si le sous-refroidissement monte et la pression haute monte, c'est une obstruction de condenseur. Ce projet reprend les résidus de cette méthode, puis pose un modèle appris dessus. La question s'impose donc : **le modèle appris apporte-t-il quelque chose ?**

La comparaison, à protocole identique

Trois candidats, même validation par machine, mêmes essais mesurés :

Méthode	accuracy	F1 macro
Gradient Boosting, référence calibrée	0,602	0,479
Arbre de décision de profondeur 3	0,558	0,422
Table de règles, référence calibrée	0,365	0,243
Gradient Boosting, référence transférée	0,318	0,290
Table de règles, sans aucune référence	0,245	0,197

(classe majoritaire : 0,251)

L'apprentissage gagne de 24 points sur la table de règles. Six règles thermodynamiques ne suffisent pas, et ce n'est plus un postulat mais une mesure.

Mais la complexité, elle, ne se justifie pas

Un arbre de décision de **profondeur 3** obtient 0,558 contre 0,602 — quatre points et demi d'écart, pour un modèle qui tient sur une feuille et se lit comme de la thermodynamique :

```
d_subcooling <= -1.24
├─ d_W_od <= 83.6   → sous-charge
└─ d_W_od > 83.6   → obstruction condenseur
d_subcooling > -1.24
├─ d_P_cond <= 0.23           → sans défaut
├─ d_P_cond <= 1.43           → débit intérieur
└─ d_P_cond > 1.43 — d_subcooling <= 4.52 → obstruction condenseur
                        └─ d_subcooling > 4.52 → surcharge
```

Sous-refroidissement qui chute : sous-charge. Qui monte avec la pression haute : surcharge. C'est exactement la physique de la section 1, retrouvée par apprentissage.

Et cet arbre dépasse l'ensemble sur la sous-charge — 0,905 contre 0,832, la panne la mieux détectée du jeu. Un ensemble de centaines d'arbres achète quatre points sur un modèle qu'un technicien peut vérifier ligne à ligne.

Deux résultats de détail

Les règles gagnent à un seul endroit : la restriction de ligne liquide, 0,136 contre 0,040. Trois fois mieux que le modèle appris sur la panne qu'il ne trouve jamais. Les deux restent mauvais en absolu, mais c'est le genre d'écart qu'une moyenne masque.

Et une hypothèse est tombée. On espérait qu'une table de règles, regardant des directions et non des valeurs, puisse diagnostiquer **sans aucune calibration** — ce qui aurait donné un outil déployable sur machine inconnue sans installation préalable. Mesuré : **0,245**, soit en dessous de la classe majoritaire. Sans référence locale, les signes seuls ne portent pas l'information.

Pour le jury. La question « votre modèle fait-il mieux qu'une règle écrite à la main ? » a une réponse chiffrée : oui, de 24 points. La question suivante — « avez-vous besoin de toute cette complexité ? » — a une réponse moins flatteuse : un arbre de profondeur 3 en récupère 93 %. Pour un déploiement terrain, c'est probablement lui le bon livrable.


13. Ce que le 0,602 suppose vraiment

Les sections précédentes annoncent 0,602 lorsque la référence saine est calibrée sur la machine cible. Un benchmark de l'estimateur de référence a mesuré ce que ce chiffre suppose — et la réponse limite sa portée.

La campagne d'essais est répliquée par construction

28 % des essais défaillants ont un essai sain à moins de 0,1 °C, et 72 % à moins de 0,5 °C. C'est logique pour une campagne contrôlée : le laboratoire teste les mêmes conditions nominales avec et sans défaut. Sur une machine en service, où les mesures saines enregistrées sont celles qui se sont présentées, ce jumeau n'existe pas.

Ce qui se passe quand on interdit le jumeau



En interdisant les voisins situés à moins de `dmin` de la condition à diagnostiquer :

dmin	accuracy
0 — protocole publié	0,602
0,1 °C	0,519
0,25 °C	0,499
0,5 °C	0,482
1,0 °C	0,452
2,0 °C	0,434

Il suffit d'exclure les voisins à 0,1 °C pour perdre huit points. La chute est immédiate, ce qui signifie que le chiffre repose sur des jumeaux quasi exacts plutôt que sur une estimation.

Trois enseignements du benchmark

Les surfaces ajustées sont plates. Régression linéaire, polynôme d'ordre 2, Ridge : environ 0,46 quel que soit `dmin`. Elles n'ont jamais utilisé les jumeaux — et n'atteignent jamais 0,602. Sur le graphique, la ligne horizontale est celle vers laquelle tous les estimateurs de voisinage convergent une fois les répliques exclues.

La médiane vaut 4,8 points. L'implémentation du projet prend la médiane des cinq voisins ; la moyenne, choix par défaut de la bibliothèque, donne 0,554. Un détail d'implémentation porte une part réelle du résultat.

Et surtout, le gain n'est pas où on croyait. Par classe, à `dmin = 0,5 °C` :

Classe	F1 à $d_{min}=0$	F1 à $d_{min}=0,5$
Sans défaut	0,735	0,434
Sous-charge	0,854	0,841

Les douze points d'accuracy perdus viennent presque entièrement de la reconnaissance de l'état **sain**. Le diagnostic des défauts de charge, lui, survit sans jumeau. L'avantage des répliques ne servait pas à nommer les pannes : il servait à reconnaître la machine en bonne santé.

Le verdict

Le 0,602 **tient comme chiffre de protocole en chambre climatique** — un essai sain existe à la même condition, c'est une propriété du plan d'expérience. Il **ne tient pas** comme performance attendue sur une machine en service, où la valeur réaliste se situe entre **0,43 et 0,52** selon la densité des mesures saines disponibles.

Pour le jury. C'est la troisième fois dans ce document qu'un chiffre change de sens selon un détail de protocole : le découpage aléatoire contre le découpage par machine, l'origine de la référence saine, et maintenant la structure du plan d'essais. Ce n'est pas une accumulation de malchance — c'est la démonstration que le protocole, et non le modèle, est ce qui porte le résultat.

14. Le chiffre survit-il hors des conditions apprises ?

Le volet simulé est validé en hold-out **aléatoire** : les exemples sont mélangés, 30 % mis de côté. Or les conditions sont tirées uniformément dans un domaine continu et densément échantillonné — un point de test a donc presque toujours un voisin d'entraînement très proche.

Le même soupçon que côté mesuré, appliqué au simulé : **le modèle reconnaît-il une panne, ou un point de fonctionnement ?**

(Mesures effectuées sur la configuration à six classes, avant l'ajout de la surcharge.)

En conditions de fonctionnement : il survit

Découpage	accuracy
Contrôle aléatoire	0,919
<code>speed_ratio > 0,85</code> tenu à l'écart	0,920
<code>GroupKFold</code> sur bacs de conditions	0,911
<code>T_ambient < -5 °C</code> tenu à l'écart	0,893
<code>T_setpoint > 48 °C</code> tenu à l'écart	0,889

Trois points de perte au pire, sur une région entière du domaine jamais vue. C'est un résultat positif, et il n'était pas acquis : c'est même l'hypothèse inverse qui était attendue.

En sévérité : il s'effondre

Deux des six classes — les défauts de ventilateur — n'ont **aucun exemple** sous une sévérité de 0,20 : le générateur ne produit jamais de ventilateur légèrement dégradé. L'analyse est donc restreinte aux quatre classes présentes des deux côtés.

Tâche	Défauts naissants	Défauts marqués
Diagnostic — nommer la panne, 4 classes	0,428	0,469
Détection — dire qu'il y a un problème	0,887	0,762

La distinction est nette et utile : **le système sait dire qu'il y a un problème sur un régime de sévérité jamais vu, mais pas lequel.**

Un détail retient l'attention : sur la sous-charge, entraîner sur les cas légers et tester sur les sévères donne 307 identifications correctes sur 307. **Apprendre une sous-charge naissante aide à reconnaître une sous-charge avancée** ; l'inverse est moins vrai.

Pour le jury. Le chiffre du volet simulé n'est pas un score de détection précoce. Il mesure la séparabilité des signatures à sévérité médiane. Un exploitant qui veut attraper une panne avant qu'elle ne coûte doit lire la ligne « détection », pas la ligne « diagnostic ».

15. Le simulateur décrit-il la réalité ?

Toute la première moitié de ce document repose sur un simulateur. Toute la seconde sur des essais mesurés. **Ils n'avaient jamais été confrontés** : entraîner sur l'un, tester sur l'autre.

C'est possible parce que le recouvrement de domaine de 5,3 % évoqué plus haut est un obstacle de **choix d'échantillonnage**, pas de physique. En tirant les conditions simulées dans le domaine NIST, la comparaison devient directe.

Périmètre : cinq classes qui se correspondent, et températures intérieures inférieures à 26 °C — au-delà, le simulateur écrête sa température d'évaporation à 20 °C et produirait des cycles déformés. Cela laisse 59 % des essais mesurés.

Trois protocoles comparables

	accuracy	F1 macro
Simulé → simulé, hold-out	0,921	0,917
Mesuré → mesuré, par machine	0,668	0,596
Simulé → mesuré	0,454	0,343

(classe majoritaire : 0,281)

Le deuxième protocole est indispensable : sans lui, on ne saurait pas si un score de 0,454 signifie que le simulateur est mauvais, ou que la tâche est simplement difficile. **Il se lit entre 0,281 et 0,668** — le simulateur transfère partiellement.

Mais la moyenne cache l'essentiel

Classe	F1, simulé → mesuré
Sans défaut	0,716
Surcharge	0,522
Sous-charge	0,445
Débit d'air évaporateur	0,031
Encrassement condenseur	0,000

Le simulateur transfère sur la charge de fluide et échoue totalement sur les échangeurs. Zéro sur l'encrassement du condenseur — pas « faible », zéro.

Et ce résultat recoupe tout le reste. La confrontation des sens de variation (section 1) avait montré que le sous-refroidissement de l'encrassement et la surchauffe du défaut de ventilateur étaient **de signe inversé**, et ils ont été corrigés. Corriger le sens n'a manifestement pas suffi à rendre l'amplitude transférable.

L'histoire est cohérente d'un bout à l'autre du projet : **la physique de la charge de fluide est juste, celle des échangeurs ne l'est pas.**

Pour le jury. C'est la seule mesure du projet qui dise ce que vaut son propre simulateur. Elle est sévère et elle est précise : il sert à démontrer et à explorer, et il sert à entraîner un modèle de terrain **pour les défauts de charge uniquement**. Un projet qui sait cela de son outil en sait plus que la plupart.

16. Conclusion

Ce que le système fait

Il modélise un cycle thermodynamique complet et en dérive des signatures de panne cohérentes ; il en fabrique un jeu d'apprentissage ; il diagnostique sept classes ; il sert le tout par une API et un tableau de bord qui se clonent et tournent sans préparation.

Et surtout, il a été **confronté à des mesures indépendantes** — ce qui a produit quatre corrections de physique, la fermeture de quatre fuites du pipeline, et cinq résultats qu'aucune simulation seule ne pouvait donner.

Ce qu'il sait de lui-même

C'est la partie inhabituelle, et c'est celle qui compte.

Question	Réponse mesurée
Que vaut le chiffre annoncé ?	89,3 % sur données simulées, hold-out, sélection sur validation
Survit-il hors des conditions apprises ?	Oui — au pire 0,889
Survit-il aux pannes naissantes ?	Non pour le diagnostic (0,43), oui pour la détection (0,89)
Quelles pannes sont détectées sur du réel ?	Les défauts de charge ; ni les débits d'air, ni la ligne liquide
Que coûte le déploiement ?	Une calibration saine sur la machine, proche des conditions à diagnostiquer
L'apprentissage est-il justifié ?	Oui , +24 points sur une table de règles — mais un arbre de profondeur 3 en récupère 93 %
Le simulateur décrit-il la réalité ?	Sur la charge oui (F1 0,45–0,52), sur les échangeurs non (0,00–0,03)

Le fil conducteur

Six fois dans ce document, un chiffre a changé de sens selon un détail de protocole : le découpage aléatoire contre le découpage par machine, l'origine de la référence saine, la structure du plan d'essais, le régime de sévérité, la présence d'une fuite d'étiquette, le jeu d'entraînement lui-même.

Ce n'est pas une accumulation de malchance. **C'est la démonstration que le protocole, et non le modèle, est ce qui porte le résultat.** Le chiffre affiché est passé de 99,8 % à 89,3 % au fil de ces corrections, et chaque baisse a rendu le projet plus vrai.

Ce qu'il ne fait pas

- Il ne détecte pas les pannes à 99 % sur le terrain.
- Il ne fonctionne pas sur une machine inconnue sans calibration préalable et proche.
- Il ne diagnostique pas les pannes naissantes, seulement les signale.
- Il ne prédit pas les pannes futures : les essais disponibles sont stationnaires, sans axe du temps. Leur en inventer un produirait exactement le genre de chiffre que ce travail s'attache à ne pas produire.

La formulation défendable

Les signatures de défaut sont séparables à 89,3 % en hold-out sur données simulées à sévérité médiane, et ce chiffre survit à l'extrapolation en conditions de fonctionnement. Confronté à des essais mesurés indépendants, le système diagnostique les défauts de charge — sur une machine réelle jamais vue, la surcharge est même identifiée sans aucune calibration — et ne sépare ni les défauts de débit d'air ni la restriction de ligne liquide.

Le simulateur, lui, transfère sur la charge de fluide et pas sur les échangeurs. Il sert à démontrer et à explorer ; il ne sert pas à entraîner un modèle de terrain, sauf sur la charge.

Annexes

Les parties précédentes racontent le système. Celles-ci permettent de le vérifier. Toutes les équations sont transcrites de `src/physics/simulator.py`, sans reformulation.

A. Symboles

Symbole	Grandeur	Unité	Nominal
T_{source}	Température de la source froide	°C	7
T_{sink}	Température du puits chaud	°C	40
n	Régime compresseur rapporté au nominal	—	0,3 à 1,0
$\varphi_{evap}, \varphi_{cond}$	Encrassement (0 = propre, 1 = obstrué)	—	0
r_{evap}, r_{cond}	Débit d'air rapporté au nominal	—	1,0
c	Charge de fluide rapportée au nominal	—	1,0
UA	Coefficient global d'échange	W/K	500 / 600
τ	Taux de compression	—	environ 3
k	Rapport des chaleurs massiques du R-410A	—	—
SH, SC	Surchauffe, sous-refroidissement	K	6,0 et 4,5

Les six paramètres φ , r et c sont les **entrées de défaut**. À leurs valeurs nominales, le cycle est sain.

B. Le modèle thermodynamique

B.1 Échangeurs

$$UA_{evap} = 500 (1 - 0,50 \varphi_{evap}) r_{evap}^{1,45} \quad UA_{cond} = 600 (1 - 0,50 \varphi_{cond}) r_{cond}^{1,45}$$
$$\Delta_{evap} = 5 + 7 \left(1 - \frac{UA_{evap}}{500}\right) \quad \Delta_{cond} = 5 + 7 \left(1 - \frac{UA_{cond}}{600}\right) + 8 (1 - r_{cond})$$

$$T_{evap} = \text{borne}(T_{source} - \Delta_{evap}, -25, 20) \quad T_{cond} = \text{borne}(T_{sink} + \Delta_{cond}, 20, 65)$$

Le terme symétrique $8(1 - r_{evap})$ côté évaporateur a été **retiré** : il faisait monter la température de refoulement avec la perte de débit, contre le sens mesuré.

B.2 Pressions et taux de compression

$$P_{evap} = P_{sat}(T_{evap}) \quad P_{cond} = P_{sat}(T_{cond})$$

Les défauts de charge agissent sur ces pressions, puis les températures de saturation sont recalculées pour rester cohérentes :

$$\begin{aligned} c < 1 : \quad P_{evap} &\leftarrow P_{evap} (0,55 + 0,45 c), & T_{evap} &\leftarrow T_{sat}(P_{evap}) \\ c > 1 : \quad P_{cond} &\leftarrow P_{cond} (1 + 0,90 (c - 1)), & T_{cond} &\leftarrow T_{sat}(P_{cond}) \\ \tau &= \frac{P_{cond}}{\max(P_{evap}, 0,5)} \end{aligned}$$

Une sous-charge affame l'évaporateur et effondre la pression basse ; une surcharge engorge le condenseur et élève la pression haute. Les deux élargissent τ , mais **par des extrémités opposées du cycle** — d'où des signatures distinctes.

B.3 Rendements du compresseur

$$\begin{aligned} \eta_{is} &= 0,75 f(\tau) g(n), & f(\tau) &= \text{borne}(1 - 0,05(\tau - 3)^2, 0,4, 1), & g(n) &= 1 - 0,30 (n - 0,7)^2 \\ \eta_{vol} &= 1 - C (\tau^{1/k} - 1), & C &= 0,05 \end{aligned}$$

C est le rapport de volumes morts. Le rendement isentropique est maximal autour de $\tau = 3$ et chute de part et d'autre.

B.4 Surchauffe et sous-refroidissement

$$SH = 6,0 (1 + 0,85 \varphi_{evap}) (1 - 0,20 (1 - r_{evap}))$$

$$SC = 4,5 (1 + 0,65 \varphi_{cond}) (1 - 0,12 (1 - r_{cond}))$$

puis, selon la charge :

$$\begin{aligned} c < 1 : \quad SH &\leftarrow SH (1 + 1,4 (1 - c)), & SC &\leftarrow SC \max(c, 0,25) \\ c > 1 : \quad SH &\leftarrow SH \max(1 - 1,4 (c - 1), 0,25), & SC &\leftarrow SC (1 + 2,2 (c - 1)) \\ SC &\leftarrow \max(SC, 0,4) \end{aligned}$$

Lecture physique de chaque terme :

Terme	Effet	Pourquoi
$+0,85 \varphi_{evap}$ sur <i>SH</i>	Encrassement évaporateur : surchauffe monte	La zone diphasique s'allonge
$-0,20 (1 - r_{evap})$ sur <i>SH</i>	Moins d'air : surchauffe baisse	Moins de chaleur absorbée en fin d'évaporateur
$+0,65 \varphi_{cond}$ sur <i>SC</i>	Obstruction condenseur : <i>SC</i> monte	Le liquide s'accumule faute d'évacuer la chaleur
$-0,12 (1 - r_{cond})$ sur <i>SC</i>	Ventilateur condenseur : effet faible	La panne élève surtout <i>T_{cond}</i>
$\max(c, 0,25)$ sur <i>SC</i>	Sous-charge : <i>SC</i> s'effondre	Plus assez de liquide à sous-refroidir
$+2,2 (c - 1)$ sur <i>SC</i>	Surcharge : le plus fort effet du modèle	Le liquide excédentaire s'empile

Les termes en gras sont ceux qui ont été **corrigés après confrontation aux mesures**. Le modèle initial les avait en sens inverse, ou absents.

B.5 Bornes du compresseur

$$T_{asp} = T_{evap} + SH$$

$$T_{ref}^{ideal} = (T_{asp} + 273,15) \tau^{\frac{k-1}{k}} - 273,15$$

$$T_{ref} = T_{asp} + \frac{T_{ref}^{ideal} - T_{asp}}{\eta_{is}} + 10 (1 - r_{cond}) - 25 (1 - r_{evap})$$

$$T_{ref} \leftarrow \min(T_{ref}, 130)$$

Les deux termes correctifs sont **calibrés sur les essais mesurés**, non dérivés : la perte de débit au condenseur réchauffe le refoulement, celle à l'évaporateur refroidit l'aspiration. Ils sont énoncés comme des paramètres ajustés.

Le plafond à 130 °C est l'enveloppe constructeur. Il était déclaré sans jamais être appliqué.

B.6 Débit, enthalpies, puissances

$$\dot{m} = V_{sw} f_{nom} n \rho_{asp} \eta_{vol} \times \begin{cases} 0,55 + 0,45 c & c < 1 \\ 1 + 0,25 (c - 1) & c > 1 \\ 0,75 + 0,25 r_{evap} & r_{evap} < 1 \end{cases}$$

$$h_1 = h_{vap}^{sat}(T_{evap}) + c_{p,vap} SH \quad h_3 = h_{liq}^{sat}(T_{cond}) - 1,5 SC \quad h_4 = h_3$$

$$\Delta h_{ideal} = c_{p,vap} (T_{ref}^{ideal} - T_{asp}) \quad \Delta h_{reel} = \frac{\Delta h_{ideal}}{\eta_{is}} \quad h_2 = h_1 + \Delta h_{reel}$$

$$Q_{evap} = \dot{m} (h_1 - h_4) \quad Q_{cond} = \dot{m} (h_2 - h_3) \quad W_{comp} = 1,10 \dot{m} \Delta h_{reel} \quad COP = \frac{Q_{cond}}{W_{comp}}$$

Le facteur 1,10 couvre les pertes mécaniques et électriques. La détente **$h_4 = h_3$** est supposée isenthalpique, hypothèse standard pour un détendeur.

B.7 Bruit de mesure

Bruit gaussien : $\pm 0,5$ °C sur les températures, 2 % sur les pressions, 3 % sur les puissances. Il est appliqué aux capteurs, puis les grandeurs dérivées sont recalculées, et la référence saine des `d_*` est bruitée indépendamment.

Grandeur dérivée	Lignes cohérentes avec ses entrées
<code>pressure_ratio</code> , <code>compression_ratio</code>	100 %
<code>COP</code>	100 %
<code>delta_T_evap</code> , <code>delta_T_cond</code>	100 %

Avant cette correction, `d_COP` valait exactement zéro pour les 2000 essais sains et pour eux seuls. Trois autres fuites (normalisation avant la CV, CV sur le jeu complet, sélection sur le test) sont fermées par un `Pipeline` `sklearn`, une CV sur le train, et un `split train / val / test`. Gardes dans `tests/test_pipeline_integrity.py`.

C. Méthodes de validation

C.1 Le résidu

$$\tilde{x} = x_{\text{observe}} - \hat{x}_{\text{sain}}(T_{\text{source}}, T_{\text{sink}}, n)$$

Cinq résidus entrent dans le vecteur : `d_T_discharge` , `d_superheat` , `d_subcooling` , `d_COP` , `d_W_comp` . La question décisive est l'origine de $\hat{x}_{\text{sain}}$:

Origine	Ce que cela suppose	Score
Simulée	Le modèle physique est exact	non mesurable sur du réel
Essais sains de la machine cible	La machine a été observée saine	0,602
Essais sains d'une autre machine	Rien	0,318

C.2 Le modèle de référence sain

$$\hat{x}_{\text{sain}}(T_{\text{source}}, T_{\text{sink}}) = \text{med}\{x_i : i \in \mathcal{V}_k\}, \quad k = \min(5, n)$$

où $\mathcal{V}_k$ désigne les k essais sains les plus proches dans le plan $(T_{\text{source}}, T_{\text{sink}})$. Des formes plus riches n'améliorent pas le transfert : polynôme d'ordre 2 avec point de rosée 0,302 ; forêt aléatoire 0,265 ; contre 0,318 pour le plus proche voisin. **Le plafond n'est pas une limite du modèle de référence, c'est une limite du transfert entre machines.**

C.3 Les deux protocoles

Protocole	Ce qu'il autorise le modèle à apprendre	Score
CV aléatoire	La panne et l'identité de la machine	0,95
Leave-one-machine-out	La panne seule	0,60

C.4 L'accord des sens de variation

$$x = \beta_0 + \beta_1 L + \beta_2 T_{source} + \beta_3 T_{sink}$$

L est le niveau de défaut ; β_2 et β_3 neutralisent les conditions d'essai. On compare **signe**(β_1) mesuré au signe de la pente simulée. Indicateur insensible au décalage de domaine, puisqu'il ne compare que des directions.

Score avant correction : 12 sur 16. Après : **20 sur 22**.

C.5 Le budget de calibration

Leave-one-machine-out dans les deux sens ; référence construite sur n essais sains de la machine testée, **retirés du jeu de test** ; vingt tirages par valeur de n .

Contrôles du protocole : $n = 0 \rightarrow 0,318$ et $n = \text{tous} \rightarrow 0,602$, retrouvés exactement.

D. Reproduire les chiffres

Chiffre	Où
89,3 % [87,6 – 90,7] simulé	<code>main_analysis.py</code> , <code>outputs/results.csv</code> (X0 / holdout-test)
0,95 / 0,602 / 0,318	<code>EDA/EDA_NIST_model.ipynb</code> , <code>EDA_NIST_reference.ipynb</code>
Accord des signes 20/22	<code>EDA/EDA_NIST_model.ipynb</code>
Budget de calibration	<code>EDA/EDA_NIST_calibration.ipynb</code>

Les classeurs NIST ne sont pas versionnés. Adresses de téléchargement et table de correspondance des 98 colonnes dans `docs/NIST_MAPPING.md` .