

Faire entrer les résultats dans le tableau de bord

P7 — de la vitrine de démo à l'échelle de vérité, `outputs/results.csv` comme source unique

Septembre 2026

0. Le problème et la contrainte fondatrice

Le tableau de bord web/ savait **appeler** un modèle. Il simule un point de fonctionnement, affiche des probabilités, trace un diagramme P^h . Il est joli. Il tourne.

Il ne montrait **rien** de ce que le dépôt a réellement établi. Les mesures de `outputs/results.csv`, les expériences $X_0 \rightarrow X_5$, le fait qu'un protocole honnête divise la performance par trois — tout cela n'existait que dans le README et dans [DOSSIER.md](#).

Un jury qui ouvre le front voyait un projet de démo. Un jury qui lit le dossier voyait un projet de recherche. C'est le même dépôt. P7 est le rattrapage : **le front doit afficher ce qu'on a mesuré**, y compris le chiffre qui dérange.

Le plan d'exécution est [FRONT PLAN.md](#). Ce document raconte ce qui a été livré, avec les captures du nouveau front.

Comment lire ce document

Comme le dossier technique, chaque étape répond à trois questions :

Physique	Quel phénomène (fuite de label, transfert de machine, fuite k^N) la figure rend visible
Apprentissage	Quelle décision de protocole le chiffre engage
Ingénierie	Pourquoi le chiffre ne vit pas dans le TSX

Ce qui a changé dans le dépôt

```
api/
+-- routers/evidence.py      GET /api/evidence/* – pandas, pas le joblib
+-- schemas/evidence.py      contrats Pydantic
+-- deps.py                  get_results() + cache mtime
+-- settings.py              results_path → outputs/results.csv

web/src/
+-- pages/EvidencePage.tsx
+-- components/ProtocolBadge.tsx
+-- components/ErrorBoundary.tsx
+-- components/evidence/     TruthLadder, ProtocolSlope, CalibrationCurve,
|                             PerClassBars, ConfusionPanel, RunsTable
+-- App.tsx                  react-router : /evidence, /models, ...

tests/test_evidence.py       CSV jouet, sans classifieur.joblib
web/e2e/evidence.spec.ts     Playwright : six figures, pas de NaN
```

La règle d'import ne change pas. Evidence **n'importe pas** FDDEngine. Une page de résultats qui exigerait le classifieur pour s'afficher dirait le contraire de ce qu'elle raconte.

1. Le principe — zéro chiffre en dur

Apprentissage. Un nombre sans protocole n'est pas un résultat. C'est la leçon de X0b, mesurée : CV aléatoire 0,937 contre leave-one-machine-out 0,602 sur les mêmes résidus (X0b / residuals / gradient-boosting, outputs/results.csv). Le front héritait du même piège que le README avant P5 : recopier « 89,3 % » dans un composant, c'est figer une capture d'écran.

Ingénierie. tools/results.py est déjà la source unique côté Python. Le garde test_readme_results_percentages_are_logged interdit au README d'afficher un pourcentage qui n'est pas journalisé. P7 étend la règle au TSX : **aucune valeur xx.x % n'est écrite dans web/src/**/*.tsx**. Tout circule :

```
outputs/results.csv → GET /api/evidence/* → composant React
```

Rejouer une expérience et appeler tools.results.log() met le dashboard à jour tout seul. Un test CI, test_web_tsx_has_no_hardcoded_result_percentages, garde la règle.

Le tableau « coût de la calibration » du README (0 / 10 / 50 essais sains) n'avait **pas** de lignes dans le CSV — le garde ne voyait que les pourcentages suivis d'un %. Les décimaux nus 0,377 et 0,456 sont maintenant journalisés (X1 / LOM0-calibration-n10 et n50). **Il n'y a toujours pas de courbe de calibration dans le front** : le plan l'interdit tant que le principe n'admet aucune exception. Journaliser n'autorise pas à redessiner.

2. L'architecture — ce qui circule

Backend — GET /api/evidence/*

Nouveau routeur `api/routers/evidence.py`, schémas dans `api/schemas/evidence.py`, dépendance `get_results()` dans `api/deps.py` (lecture CSV + cache mtime, le motif de `get_dataset`).

Endpoint	Rend	Figure
/api/evidence/summary	8 expériences, 660 mesures, 20 protocoles, headline 89,3 % et son protocole	bandeau
/api/evidence/ladder	l'échelle de vérité, chaque barre portant sa cause	1
/api/evidence/protocols	X0b : 4 jeux de grandeurs × 2 protocoles	2
/api/evidence/references	X3 : grille famille × conditionnement × \$d_{\min}\$	3
/api/evidence/per-class	F1 par classe, trois régimes, classes alignées côté serveur	4
/api/evidence/confusion	matrice hold-out (sim2real : 404 tant que l'artefact n'existe pas)	5
/api/evidence/runs	les 660 lignes, filtrables, 50 par page	6

Les routes sont des `def` : pandas est bloquant, FastAPI les pousse dans le threadpool. Pas d'async cosmétique. CSV absent → `ArtifactMissing` → 404, jamais une 500. Un test tourne sur un CSV jouet écrit dans `tmp_path`, via `create_app(Settings(results_path=...))`, **sans** le joblib livré.

La correspondance des classes vit dans `_CLASS_ALIGN` de `api/routers/evidence.py`, pas dans le TSX. Le simulateur parle `Refrigerant_Overcharge` ; NIST parle `Overcharge`. Un zéro côté simulateur pour `LiquidLine` dirait « mesuré et nul ». Un trou dit « pas mesurable ». Le serveur envoie `null`. Le front dessine un emplacement vide.

Front — la page Evidence

Septième item de sidebar, icône fiole, **deuxième position** — juste après Insights. Route partageable : `/evidence`.

Style : le verre existant. `GlassCard`, `tooltipStyle`, `recharts`, bordures `rgba(255,255,255,0.18)`. Pas de second langage visuel pour la moitié sérieuse de l'application.




Le bandeau affiche ce que le journal contient **aujourd'hui** : 8 expériences, 660 mesures, 20 protocoles, accuracy headline **89,3 %** avec la puce hold-out · simulated. Ces quatre nombres ne sont pas dans le TSX.

ProtocolBadge — le composant qui change tout


Une puce de verre, posée sur **chaque chiffre d'Evidence**, et sur le 89,3 % d'Insights et de Models :

[hold-out · simulated] [LOMO · NIST] [random CV ▲]

Un jury qui voit 89,3 % sans savoir sur quoi ne peut rien en faire. La puce répond avant qu'il pose la question. C'est X0b rendue visible.




Le sous-titre d'Insights ne dit plus « calibrated Gradient Boosting ». Il dit **Random Forest**, le modèle livré. Models ne dit plus « 23 residual features » : les 23 colonnes ne sont pas toutes des résidus. Refrigerant_Overcharge a enfin une couleur propre dans FAULT_COLORS — le collisionneur P4 est fermé.



3. Les six figures

Figure 1 — L'échelle de vérité

C'est la figure la plus importante du dépôt. Barres horizontales, une seule teinte (magnitude, pas identité), chacune annotée de **ce qu'on a retiré** pour passer à la suivante.



Marche	Accuracy	Protocole	Cause
99,6 %	X0 / leaked-dCOP / 24-col	simulé	d_COP fuitait le label
91,9 %	X0 / holdout-test-6class	simulé	6 classes, dont une fantôme
89,3 %	X0 / holdout-test / 23-col / RF	simulé	7 classes, hold-out honnête
—	filet	—	frontière simulateur NIST
60,2 %	X0b / LOMO / residuals / GB	machine cible	résidus, référence sur la cible
45,4 %	X5 / sim2real / residuals / RF	mesuré	entraîné sur le simulateur
31,8 %	X1 / LOMO / training-machine	transféré	référence d'une autre machine
25,1 %	X0b / majority-class	—	classe majoritaire


Deux règles, non négociables, et tenues :

1. **Une séparation franche entre simulateur et NIST.** Ce ne sont pas les mêmes données. Une rampe continue laisserait croire à une dégradation unique.
2. **Une ligne pointillée à 25,1 %.** Sans elle, 31,8 % ressemble à un échec ; avec elle, on voit que c'est au-dessus du hasard, à peine.

Physique. La chute 99,6 → 89,3 n'est pas un modèle plus faible : c'est d_COP qui **était** le label (== 0 sur toutes les lignes saines, et sur aucune autre classe). La chute 89,3 → 60,2 n'est pas non plus un estimateur : c'est le passage d'un monde où le simulateur fabrique les questions **et** les réponses, à deux machines de chambre climatique.

Figure 2 — Le protocole pèse plus que le modèle

Slopegraph. Quatre jeux de grandeurs, deux colonnes (CV aléatoire, LOMO), un trait par jeu. La donnée intéressante est la **pente**, pas les hauteurs. Légende en bout de trait, pas de boîte.



Grandeurs	CV aléatoire	LOMO
raw+residuals	0,973	0,562
raw	0,954	0,333
residuals+conditions	0,945	0,594
residuals	0,937	0,602

L'écart de protocole ($\sim 0,4$) écrase l'écart de features ($\sim 0,04$). residuals est le seul trait à peu près plat — et le seul à **monter** en LOMO. La puce random CV $\triangle$ est là pour ça : ce n'est pas un score utilisable en champ.

Figure 3 — Le benchmark des références saines (X3)

C'est le jeu le plus riche du dépôt, et il n'était publié nulle part. X3 balaie une grille de modèles de référence sain : famille (global-mean, $k \in \{1, 5, 10, 20\}$, poly2), conditionnement (TT ou TTdew), $d_{\min} \in \{0; 0,1; 0,25; 0,5; 1; 2\}^\circ\text{C}$.

Physique. $d_{\min}$ n'est pas un hyperparamètre. C'est un garde-fou contre la fuite. À $d_{\min}=0$, un essai en défaut peut avoir son jumeau sain à $0,05^\circ\text{C}$ dans le jeu de référence — le $k=1$ le retrouve et le score explose. C'est l'artefact qui a failli être publié comme une amélioration de +10 points.



Échelle Y identique sur toutes les facettes. Ligne pointillée à la classe majoritaire. Annotation journalisée : knn-k5-median-unif / TT / $d_{\min}=0$ donne 0,602 ; le même modèle à $d_{\min}=0,5$ donne 0,482. La pente est le diagnostic de fuite.

Figure 4 — Par classe, trois régimes

Trois séries, trois lignes de journal, classes alignées côté serveur, tri sur le plafond NIST (référence machine cible).

Série	Source	Ce que c'est
Simulateur	X5 / holdout-test / simulated	le chiffre vitrine
NIST, cible	X1 / LOMO / target-machine	le plafond réaliste
NIST, transféré	X1 / LOMO / training-machine	machine réellement inconnue




Deux faits, parce que c'est ce que la figure révèle :

- **Overcharge monte** quand la référence est transférée (0,674 → 0,786). Une surcharge se voit sans calibration : sa signature est absolue, pas relative à la machine. C'est le seul défaut déployable en l'état.
- **LiquidLine est à 0,040**. Jamais détecté. Le simulateur ne le modélise pas. On l'affiche quand même, avec un **trou** côté simulateur — pas un zéro.

Figure 5 — Matrice de confusion

Heatmap, rampe séquentielle une teinte, 2 px entre les cellules, valeurs écrites. Sélecteur de protocole au-dessus : hold-out simulé (artefact outputs/synthetic/confusion_matrix.csv) ou sim2real. Tant que la matrice sim2real n'est pas un CSV versionné, le sélecteur dit l'absence au lieu d'inventer des zéros.



Apprentissage. Les ventilateurs restent séparés (0,95 / 0,99). L'encrassage de condenseur perd 0,25 vers Normal — c'est la physique du pincement, pas un bug d'estimateur. Le dossier le dit déjà ; le front le montre.

Figure 6 — Les 660 mesures

Table filtrable (expérience / protocole / modèle / classe), triable, colonne \$\$, 50 lignes, un bouton. C'est la pièce justificative : un jury sceptique doit pouvoir descendre de n'importe quel graphe jusqu'à la ligne de CSV.

Logged measurements

660 rows in `outputs/results.csv`

HOLDOUT-DOMAIN-TSET>48 · SIMULATED

Experiment
All experiments

Protocol
All protocols

Model
All models

Class
All classes

Exp	Protocol	Reference	Features	Model	Class	Metric	Value	n
P5	holdout-domain-Tset>48	simulated	23-col	random-forest	__global__	accuracy	0.896	1366
P5	holdout-domain-Tset>48	simulated	23-col	random-forest	__global__	f1	0.873	1366
P5	holdout-domain-Tset>48	simulated	23-col-minus-dead	random-forest	__global__	accuracy	0.898	1366
P5	holdout-domain-Tset>48	simulated	23-col-minus-dead	random-forest	__global__	f1	0.878	1366
P5	holdout-domain-Tset>48	simulated	residuals	random-forest	__global__	accuracy	0.764	1366
P5	holdout-domain-Tset>48	simulated	residuals	random-forest	__global__	f1	0.721	1366
P5	holdout-domain-Tset>48	simulated	residuals+conditions	random-forest	__global__	accuracy	0.770	1366
P5	holdout-domain-Tset>48	simulated	residuals+conditions	random-forest	__global__	f1	0.727	1366
P5	holdout-test	simulated	23-col	random-forest	__global__	accuracy	0.893	1500
P5	holdout-test	simulated	23-col	random-forest	__global__	f1	0.871	1500
P5	holdout-test	simulated	23-col-minus-dead	random-forest	__global__	accuracy	0.895	1500
P5	holdout-test	simulated	23-col-minus-dead	random-forest	__global__	f1	0.875	1500
P5	holdout-test	simulated	residuals	random-forest	__global__	accuracy	0.823	1500
P5	holdout-test	simulated	residuals	random-forest	__global__	f1	0.783	1500
P5	holdout-test	simulated	residuals+conditions	random-forest	__global__	accuracy	0.823	1500
P5	holdout-test	simulated	residuals+conditions	random-forest	__global__	f1	0.785	1500
X0	cv-train	simulated	23-col	random-forest	__global__	f1	0.886	2625
X0	cv-train	simulated	24-col	random-forest	__global__	f1	0.881	2625
X0	holdout-test	simulated	23-col	gradient-boosting	__global__	accuracy	0.899	1500
X0	holdout-test	simulated	23-col	gradient-boosting	__global__	f1	0.879	1500
X0	holdout-test	simulated	23-col	random-forest	__global__	accuracy	0.893	1500
X0	holdout-test	simulated	23-col	random-forest	__global__	f1	0.871	1500
X0	holdout-test	simulated	24-col	gradient-boosting	__global__	accuracy	0.905	1500
X0	holdout-test	simulated	24-col	gradient-boosting	__global__	f1	0.882	1500
X0	holdout-test	simulated	24-col	random-forest	__global__	accuracy	0.893	1500
X0	holdout-test	simulated	24-col	random-forest	__global__	f1	0.872	1500
X0	holdout-test-6class	simulated	24-col	random-forest	__global__	accuracy	0.919	1500
X0	leaked-dCOP	simulated	24-col	random-forest	__global__	accuracy	0.996	5000
X0b	LOMO	target-machine	raw	gradient-boosting	__global__	accuracy	0.333	5386
X0b	LOMO	target-machine	raw+residuals	gradient-boosting	__global__	accuracy	0.562	5386
X0b	LOMO	target-machine	residuals	gradient-boosting	__global__	accuracy	0.602	5386
X0b	LOMO	target-machine	residuals+conditions	gradient-boosting	__global__	accuracy	0.594	5386
X0b	majority-class	none	nan	baseline	__global__	accuracy	0.251	5386
X0b	random-cv	target-machine	raw	gradient-boosting	__global__	accuracy	0.954	5386
X0b	random-cv	target-machine	raw+residuals	gradient-boosting	__global__	accuracy	0.973	5386
X0b	random-cv	target-machine	residuals	gradient-boosting	__global__	accuracy	0.937	5386
X0b	random-cv	target-machine	residuals+conditions	gradient-boosting	__global__	accuracy	0.945	5386
X1	LOMO	target-machine	residuals	gradient-boosting	Cond_Blockage	f1	0.299	497
X1	LOMO	target-machine	residuals	gradient-boosting	Cond_Blockage	precision	0.611	497
X1	LOMO	target-machine	residuals	gradient-boosting	Cond_Blockage	recall	0.220	497
X1	LOMO	target-machine	residuals	gradient-boosting	Evap_Airflow	f1	0.288	774
X1	LOMO	target-machine	residuals	gradient-boosting	Evap_Airflow	precision	0.269	774
X1	LOMO	target-machine	residuals	gradient-boosting	Evap_Airflow	recall	0.313	774
X1	LOMO	target-machine	residuals	gradient-boosting	LiquidLine	f1	0.040	593
X1	LOMO	target-machine	residuals	gradient-boosting	LiquidLine	precision	0.000	593
X1	LOMO	target-machine	residuals	gradient-boosting	LiquidLine	recall	0.000	593

X1	LOMO	target-machine	residuals	gradient-boosting	LiquidLine	precision	0.206	593
X1	LOMO	target-machine	residuals	gradient-boosting	LiquidLine	recall	0.068	593
X1	LOMO	target-machine	residuals	gradient-boosting	No_Fault	f1	0.741	1352
X1	LOMO	target-machine	residuals	gradient-boosting	No_Fault	precision	0.722	1352
X1	LOMO	target-machine	residuals	gradient-boosting	No_Fault	recall	0.837	1352
X1	LOMO	target-machine	residuals	gradient-boosting	Overcharge	f1	0.674	942

Load 50 more

Le pied affiche outputs/results.csv. Modifier ce fichier et recharger /evidence change le dashboard, sans toucher au TSX.

4. La dette front soldée dans la foulée

Ces points étaient identifiés avant P7 ; les traiter ici évite une quatrième livraison orpheline.

Point	Ce qui a été fait
Types dupliqués dans api.ts	npm run gen:api (tools/export_openapi.py + openapi-typescript), sortie versionnée web/src/api.generated.ts
Pas d'AbortController	chaque useEffect qui fetch annule au cleanup — Insights en lance plusieurs en parallèle
Pas d'ErrorBoundary	une frontière par route ; une exception de rendu ne vide plus l'écran
Navigation useState	react-router-dom : /, /evidence, /live, /diagnose, /models, /thermo
Pas d'ESLint	eslint + typescript-eslint + react-hooks, job CI web
Pas de test front	Playwright ouvre /evidence, attend les 6 figures, refuse NaN / undefined

Le routeur conditionne le reste : sans URL, aucun graphe n'est envoyable à un jury.

5. Ce que P7 ne prétend pas

- **Ce n'est pas un modèle de RUL.** Le classifieur nomme l'état présent. Le CSV iid n'a pas d'axe temporel de dégradation.
- **Ce n'est pas la courbe de budget de calibration.** Les 0,377 / 0,456 sont journalisés pour le garde README ; ils n'ont pas de figure.
- **Ce n'est pas X3 en entier.** L'API sert toute la grille accuracy ; le front facette les familles que le plan nomme (global-mean, \$k\$NN \$k=1/5/10/20\$, poly2). ridge, lin, les agrégateurs \$k\$NN autres que median-unif restent dans la table §6.
- **La puce n'est pas encore sur chaque COP de Diagnose.** Elle est sur Evidence, et sur le 89,3 % d'Insights et de Models — là où un jury confondrait un hold-out simulé avec un champ.

6. Reproduire

```
.venv/bin/uvicorn api.app:app --reload          # http://127.0.0.1:8000/docs
cd web && npm run dev                          # http://localhost:5173/evidence
```

Evidence se charge **sans** `models/synthetic/classifier.joblib`. Les autres pages (Diagnose, Live) en ont besoin.

```
.venv/bin/python -m pytest tests/test_evidence.py tests/test_docs.py -q
cd web && npm run lint && npm run build && npm run test:e2e
```

Les captures de ce document se régénèrent, API et Vite allumés, par `web/scripts/capture_evidence.mjs`.

Où vit chaque chiffre

Chiffre	Ligne de <code>outputs/results.csv</code>
89,3 %	X0 / holdout-test / 23-col / random-forest / accuracy
99,6 %	X0 / leaked-dCOP
91,9 %	X0 / holdout-test-6class
0,602 / 0,318 / 0,251	X0b LOMO residuals, X1 training-machine, majority-class
0,454	X5 / sim2real / measured-knn5
0,937 vs 0,602	X0b random-cv vs LOMO, residuals
Overcharge 0,674 → 0,786	X1 LOMO target- vs training-machine, label Overcharge, f1
LiquidLine 0,040	X1 LOMO target-machine, label LiquidLine, f1
kNN k=5 $d_{\{\min\}} 0 \rightarrow 0,5$	X3 / knn-k5-median-unif-TT-dmin0 et dmin0.5

Le dossier [DOSSIER.md](#) raconte *pourquoi* ces protocoles existent. Cette page raconte *comment* un jury les voit sans ouvrir un CSV.